Trabalho Series Temporais

Grupo 6; Região: Norte

Rodrigo Ferrão: a2022138105

Tomás Moreira: a2023143375

Licenciatura Ciência de Dados 2025/2026

Unidade Curricular: Series Temporais

Docente: Joana Leite

Índice

1. Introdução 3

2. Extração dos Dados 4

2.1 Análise do Desfasamento de Informação (Data Lag) 4

2.2 Pré-processamento e Limpeza 4

3. Análise Exploratória 5

3.1 Evolução Temporal da Série 5

3.2 Análise Focada: Dinâmica Recente e Padrões de Calendário 7

3.3. Decomposição da Série e Padrão Semanal 9

4. Determinação do melhor método de previsão 10

4.1 Métodos de previsão considerados 10

4.2. Preparação dos Dados e Definição da Janela Temporal 12

4.3. Avaliação das capacidade preditiva e seleção do melhor método 12

5. Previsão objetivo 14

5.1 Melhor modelo 14

5.2 Análise dos resíduos 15

5.2.1 Validação Estatística 15

5.3. Previsões Objetivo e Análise de Desvios 16

5.3.1. Confronto com a Realidade: A "Normalidade" vs o "Surto" 16

5.3.2. Interpretação Visual e Operacional 17

..... 18

6. Procedimento 18

7. Conclusão 19

1. Introdução

A monitorização da síndrome gripal constitui um elemento crítico no planeamento da saúde pública em Portugal. A capacidade de antecipar picos de procura nos Cuidados de Saúde Primários (CSP) permite aos gestores hospitalares e às Administrações Regionais de Saúde (ARS) alocar recursos humanos e materiais de forma eficiente, mitigando a pressão sazonal sobre o Serviço Nacional de Saúde (SNS).

No âmbito da unidade curricular de Séries Temporais, este trabalho tem como objetivo desenvolver um modelo preditivo robusto para estimar o número diário de consultas por síndrome gripal na região da **ARS Norte**. O desafio central consiste em simular um ambiente operacional realista, onde as previsões devem ser geradas para um horizonte de 14 dias (h=14), utilizando exclusivamente a informação histórica disponível 3 dias antes do início do período de previsão. Esta restrição, conhecida como *gap* de informação ou *lag*, reflete os atrasos habituais na consolidação e disponibilização de dados administrativos.

A abordagem metodológica baseia-se no ciclo completo de análise de dados, desde a extração automatizada via API do Portal da Transparência do SNS até à modelação avançada. O estudo divide-se em dois horizontes temporais: uma análise histórica alargada (2016-2025) para compreender tendências de longo prazo e impactos estruturais (como a pandemia COVID-19), e um período de foco (setembro de 2024 a outubro de 2025) para o treino e validação dos modelos. Utilizando a linguagem **Python** e bibliotecas especializadas como statsmodels e StatsForecast (Nixtla), foram comparados métodos de referência (*benchmarks*) com modelos de Alisamento Exponencial (ETS) e modelos AutoRegressivos Integrados de Médias Móveis (ARIMA/SARIMA), selecionados com base na minimização de métricas de erro em validação cruzada.

2. Extração dos Dados

A recolha de dados foi automatizada através da *Application Programming Interface* (API) do Portal da Transparência do SNS. Utilizando a biblioteca requests em Python, estabeleceu-se uma conexão ao *dataset* "Atendimentos nos CSP - Gripe" para a região da **ARS Norte**. Para garantir a integridade da extração e contornar eventuais limitações de *timeout* do servidor ou limites de registos por pedido, implementou-se um algoritmo de extração segmentada, o intervalo temporal total (2016-2025) foi dividido em lotes de 100 dias. Esta abordagem iterativa permitiu descarregar o histórico completo sem interrupções, concatenando os resultados num único *DataFrame* consolidado.

2.1 Análise do Desfasamento de Informação (Data Lag)

Em conformidade com os requisitos do enunciado, procedeu-se à investigação do tempo de latência entre a ocorrência real das consultas e a sua disponibilização pública na plataforma. À data da execução do código a 18-01-2026, a última observação disponível no sistema reportava ao dia 16-01-2026.

Calculou-se, assim, um atraso (*gap*) de 2 dias. Esta verificação empírica valida a premissa do trabalho num cenário operacional real, os gestores não dispõem de dados em tempo real. A restrição imposta de utilizar apenas informação disponível até 3 dias antes do período de previsão revela-se, portanto, uma aproximação realista (e até otimista, considerando o *lag* atual) das condições de tomada de decisão no SNS.

```
A extrair dados para ARS Norte (2016-11-01 a 2026-01-18)...
   -> A extrair dados em 34 lotes

 ANÁLISE DO GAP
   Hoje é: 2026-01-18
   Último dado no SNS: 2026-01-16
   Atraso Real (GAP): 2 dias
   (No dia 3 de Dez, só veríamos dados até dia 1)
```

2.2 Pré-processamento e Limpeza

Após a extração, os dados foram submetidos a um processo de transformação para se adequarem aos requisitos da biblioteca de modelação StatsForecast (Nixtla):

1. **Renomeação:** A variável temporal foi mapeada para ds e a variável de interesse (*no_consultas_gripe_nos_csp*) para y.

2. **Continuidade Temporal:** Foi forçada a criação de um índice diário completo para detetar dias em falta. Identificaram-se 0 dias sem registos.

3. **Imputação:** Para garantir a robustez dos modelos de séries temporais (que não admitem falhas na frequência), estes valores ausentes foram preenchidos através de interpolação linear, assumindo uma transição suave entre os dias adjacentes.

3. Análise Exploratória

Antes da aplicação de algoritmos de previsão, procedeu-se à inspeção visual da série temporal referente às consultas de síndrome gripal na região ARS Norte (2016-2025) para identificar os seus componentes estruturais (tendência, sazonalidade e eventuais quebras estruturais).

3.1 Evolução Temporal da Série

A análise do gráfico de evolução histórica desde 2016 - 2025 (Figura 1) permite constatar que a série não é estacionária, apresentando um comportamento fortemente cíclico.

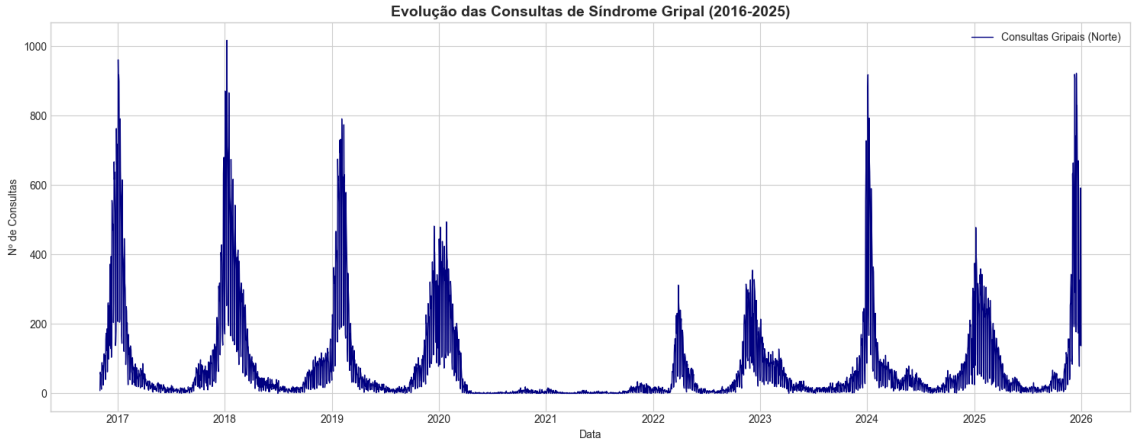

Figura 1

- **Padrão Oscilatório:** Observa-se uma alternância clara entre períodos de procura residual (meses de verão) onde apresenta valores baixos e picos abruptos de procura onde apresenta valores mais altos (meses de inverno).

- **Volatilidade dos Picos:** A magnitude dos picos varia de ano para ano, sugerindo que a intensidade da época gripal depende de fatores externos (estirpes do vírus, temperatura, taxas de vacinação).

- **Estacionaridade:** A ausência de uma tendência de crescimento linear contínua a longo prazo facilita a utilização de modelos estatísticos clássicos, embora a variância nos picos exija robustez no tratamento de outliers.

Nos anos 2020-2022 mal ocorre oscilações uma vez que se deu como ocorrido o período pandémico, quando a população teve de permanecer em casa e isso fez com que as consultas apresentassem o menor valor alguma vez registado.

3.1.2 Padrões de Sazonalidade Anual

Para isolar e compreender o perfil intra-anual da gripe, procedeu-se à sobreposição dos anos civis num gráfico de sazonalidade (Figura 2). Esta representação confirma a existência de um padrão sazonal extremamente rígido, que desenha visualmente uma forma de "U" ao longo do ano.

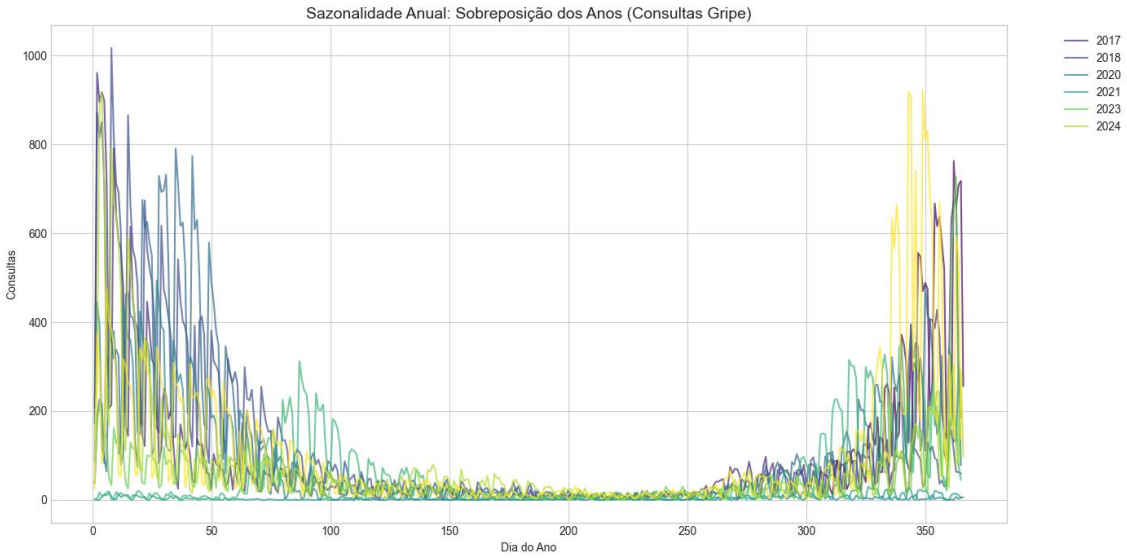

Figura 2

A análise deste gráfico permite identificar com precisão a "janela crítica" de pressão sobre o Serviço Nacional de Saúde. Verifica-se que a procura atinge sistematicamente os seus valores mínimos entre os dias 150 e 250 do ano (aproximadamente de junho a setembro), voltando a escalar rapidamente nas últimas semanas do ano (semana 48 em diante) e mantendo-se elevada nas primeiras semanas do ano seguinte (semana 1 a 8).

A consistência deste padrão, que se repete ano após ano com poucas exceções, valida a hipótese de que o histórico passado é um forte preditor do comportamento futuro. Este diagnóstico reforça a necessidade de utilizar modelos de previsão como o AutoARIMA

ou AutoETS, especificamente configurados para capturar esta sazonalidade forte e recorrente.

3.2 Análise Focada: Dinâmica Recente e Padrões de Calendário

Após a validação da tendência global, a análise exploratória afunilou o seu foco para o período mais recente, compreendido entre **01 de setembro de 2024 e 31 de outubro de 2025**. Este recorte temporal permite observar a "textura" diária da procura com maior grão, livre do ruído de anos históricos distantes, facilitando a identificação de padrões operacionais imediatos.

3.2.1 Evolução Recente e Intensidade Mensal

A inspeção visual da evolução recente (Figura 3) revela uma dinâmica de "dentes de serra", onde a tendência de fundo (o surto gripal) é constantemente interrompida por oscilações de alta frequência. Estas oscilações não são ruído aleatório, mas sim um reflexo da operação dos serviços de saúde, sugerindo uma forte componente semanal que necessita de ser modelada explicitamente.

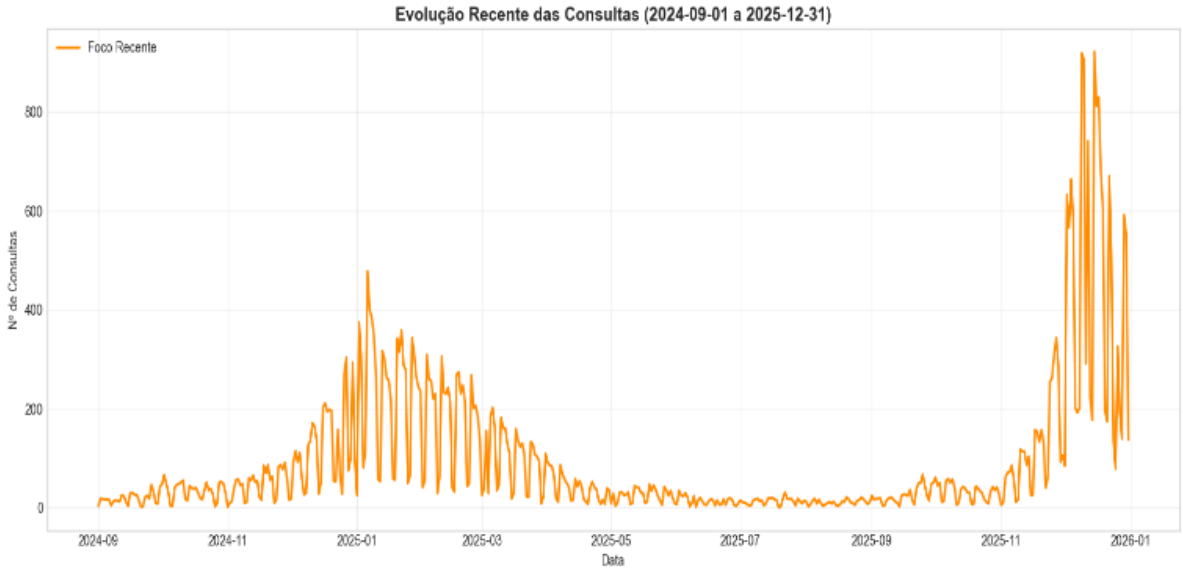

Figura 3

Para corroborar a sazonalidade macroscópica, utilizou-se um Mapa de Calor (Heatmap) de Intensidade Mensal (Figura 4), cruzando os anos (eixo X) com os meses (eixo Y). A visualização térmica confirma inequivocamente que a pressão sobre o sistema não é uniforme:

- Observa-se uma concentração de "zonas quentes" (vermelho/laranja) consistentemente nos meses de dezembro, janeiro e fevereiro.
- Em contraste, os meses de verão (junho a setembro) apresentam-se sistematicamente como "zonas frias" (azul), indicando uma procura residual.

Esta consistência cromática ao longo dos anos valida a previsibilidade do fenómeno: embora a gravidade varie, a janela temporal de ocorrência é estável.

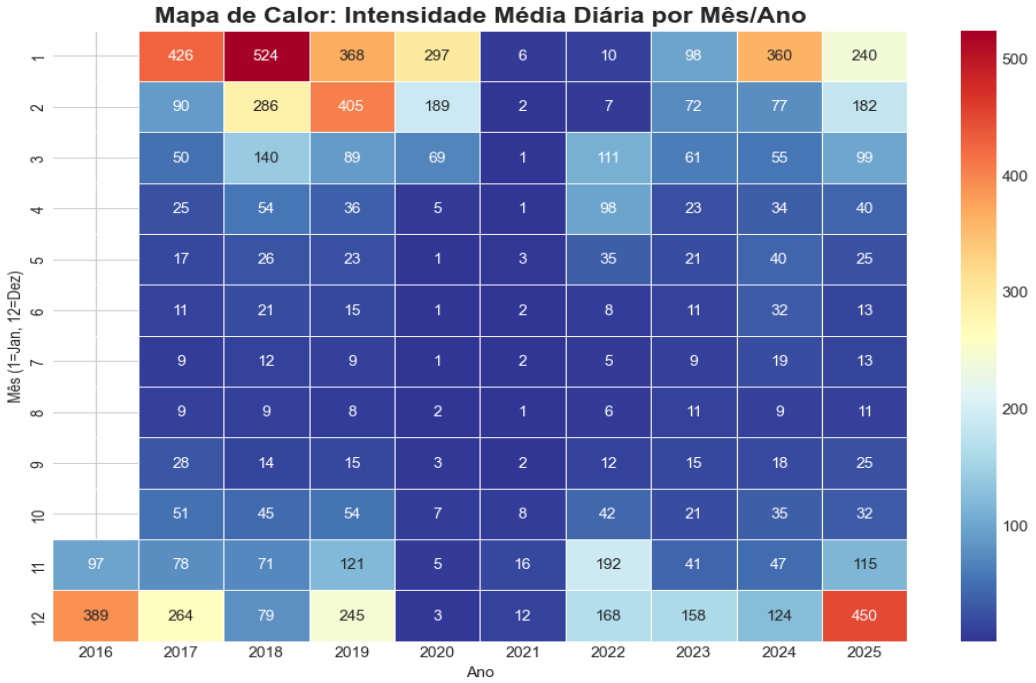

Figura 4 (Heatmap)

3.2.2 O "Efeito de Fim de Semana": Análise Intra-semanal

A descoberta mais impactante desta fase exploratória, determinante para a estratégia de modelação subsequente, reside no comportamento intra-semanal da procura. Através da análise de distribuição por dia da semana, utilizando *Boxplots* e, com maior detalhe, *Violin Plots* (Figura 5), identificou-se um padrão comportamental rígido:

1. **O "Efeito de Segunda-Feira":** As segundas-feiras apresentam consistentemente as medianas mais elevadas e as caudas de distribuição mais longas (maior variância). Este fenómeno é explicado pela acumulação de sintomatologia durante o fim de semana, levando os utentes a procurar cuidados logo no primeiro dia útil.
2. **Declínio Semanal:** A procura tende a estabilizar ou decrescer ligeiramente de terça a sexta-feira.

3. **Quebra de Fim de Semana:** Sábados e domingos registam uma queda abrupta no volume de consultas. O formato "achatado" e largo dos *Violin Plots* nestes dias indica uma densidade de probabilidade concentrada em valores baixos, com muito pouca dispersão.

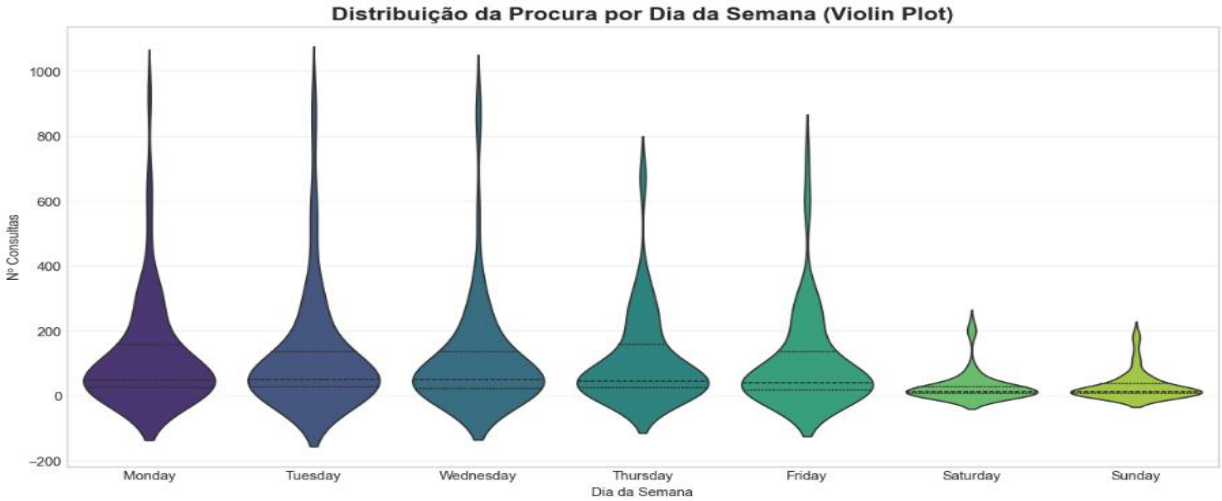

Figura 5

3.3. Decomposição da Série e Padrão Semanal

Para validar a estrutura dos dados no período de foco (01/09/2024 a 31/10/2025), aplicou-se o método de decomposição STL (Seasonal-Trend decomposition using Loess) com modelo aditivo. A análise visual dos componentes segregados (Figura 6) permitiu isolar a "curva epidemiológica" (Tendência) da variabilidade diária. O componente sazonal

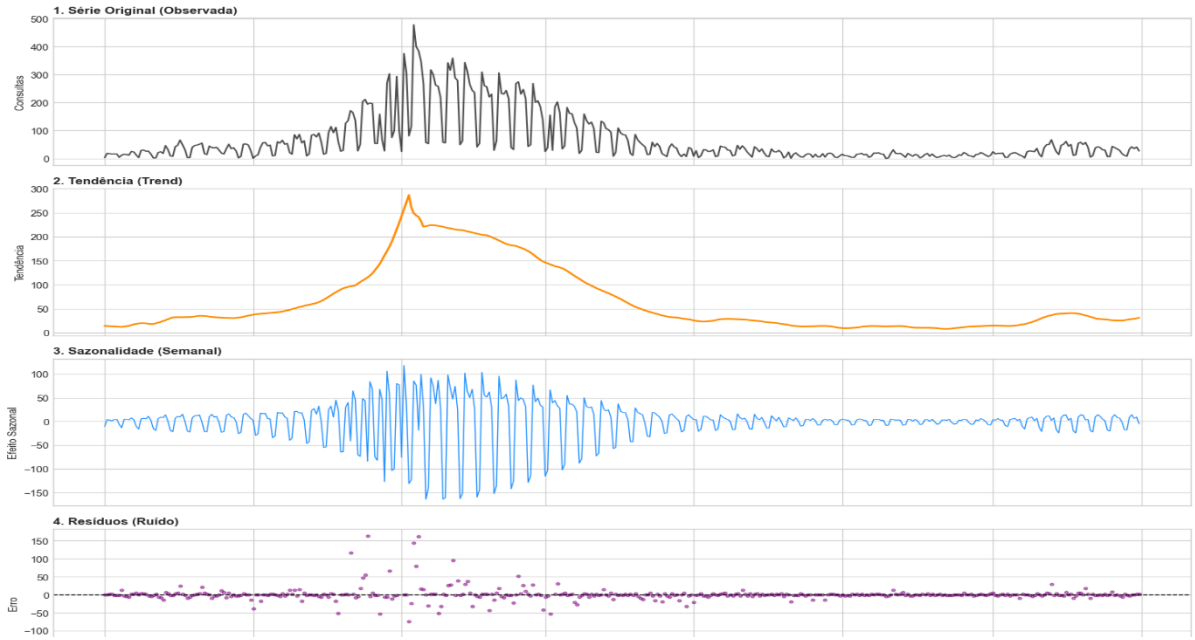

Figura 6

revelou-se dominante na alta frequência, exibindo um padrão cíclico rígido de 7 dias. Crucialmente, a análise dos Resíduos (erro) identificou *outliers* negativos coincidentes com feriados a meio da semana, evidenciando que um modelo puramente cíclico falha nestas datas excecionais, o que justifica a necessidade técnica de incluir regressores exógenos na modelação preditiva.

Aprofundando a análise do ciclo intra-semanal (Figura 7), confirma-se estatisticamente o "efeito de segunda-feira", onde a procura média atinge o seu máximo semanal, absorvendo o represamento de sintomas do fim de semana. Em contraste, sábados e domingos apresentam uma redução abrupta e consistente da procura (baixa dispersão nos *boxplots*). Esta anatomia assimétrica da semana valida matematicamente a definição do parâmetro de sazonalidade (season_length=7), demonstrando que o dia da semana é o preditor determinante para a oscilação diária de curto prazo.

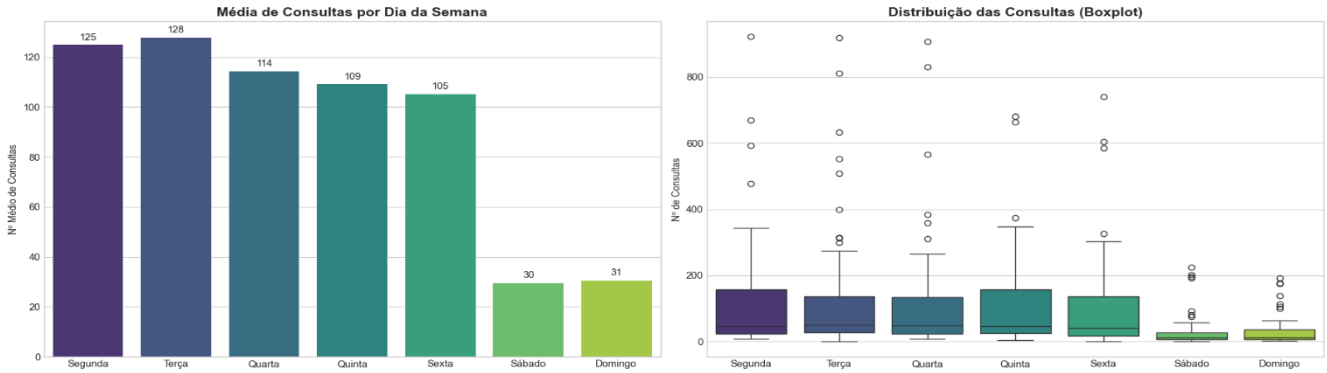

Figura 7

4. Determinação do melhor método de previsão

4.1 Métodos de previsão considerados

4.1.1 Abordagem sem preditores exógenos

Nesta primeira etapa, o objetivo foi estabelecer uma *baseline* de desempenho e compreender se a dinâmica da série temporal poderia ser explicada apenas pela sua própria inércia. Foram testados três algoritmos com periodicidade semanal (season_length=7), como mostra a figura 8:

1. **Seasonal Naive:** Modelo de referência (*benchmark*) que assume que a procura de hoje será igual à do mesmo dia da semana anterior. Serve como ponto de controlo mínimo.

2. **AutoETS:** Modelo de Espaço de Estados (Erro, Tendência, Sazonalidade), eficaz na captura de padrões multiplicativos e aditivos sem necessidade de regressores externos.

3. **AutoARIMA (Univariado):** Versão puramente autorregressiva, sem inclusão de variáveis de calendário.

```
TABELA DE COMPARATIVA DE MÉTRICAS
      Modelo       MAE      RMSE
     AutoETS 19.040001 37.529999
   AutoARIMA 19.680000 37.090000
SeasonalNaive 20.469999 39.150002

Modelo Recomendado (Menor MAE): AutoETS
```

Figura 8

Nesta configuração inicial, o AutoETS revelou-se o modelo mais competente, apresentando o menor Erro Médio Absoluto (19.04). É notável observar que, sem a informação de feriados, o sofisticado AutoARIMA teve um desempenho praticamente idêntico (MAE de 19.04 vs 19.68). Isto evidencia uma limitação crucial, modelos autorregressivos "cegos" ao calendário civil não conseguem distinguir uma quarta-feira normal de uma quarta-feira de feriado, falhando na previsão dessas quedas abruptas.

Este diagnóstico justificou a necessidade de avançar para a fase multivariada, testando se a inclusão de variáveis exógenas permitiria ao ARIMA superar a performance do ETS.

4.1.2 Abordagem sem preditores exógenos

Na segunda fase experimental, procurou-se superar as limitações dos modelos univariados através da incorporação de conhecimento externo sobre o calendário. Foi criada e injetada no modelo AutoARIMA uma variável binária (Feriado), sinalizando dias de paragem nacional e tolerâncias de ponto, sob a hipótese de que esta informação ajudaria a reduzir os erros de previsão em dias não úteis atípicos que o modelo estatístico simples não consegue antecipar.

Figura 9

```
TABELA FINAL
      Modelo   MAE  RMSE
   AutoARIMA 18.98 35.69
     AutoETS 19.04 37.53
SeasonalNaive 20.47 39.15

Modelo Vencedor: AutoARIMA
```

A análise comparativa valida inequivocamente a eficácia da inclusão de variáveis exógenas, superando o cenário de "empate técnico" observado na fase univariada, como mostra a figura 9. O AutoARIMA destacou-se nesta etapa como o algoritmo superior em todas as métricas, registando o menor Erro Médio Absoluto (MAE de 18.98 face aos 19.04 do AutoETS). Embora esta diferença na precisão média seja marginal, ela demonstra uma maior sensibilidade do modelo às nuances diárias do calendário civil. A vantagem torna-se substancialmente mais expressiva na análise da robustez (RMSE de 35.69 contra 37.53), confirmando que a variável Feriado foi determinante para eliminar os grandes resíduos tipicamente associados a paragens a meio da semana. Consequentemente, dado que o AutoARIMA provou ser simultaneamente o modelo mais consistente na média e o mais seguro na gestão de erros extremos, foi selecionado como a ferramenta final para a previsão da semana alvo, substituindo a abordagem puramente estatística do ETS.

4.2. Preparação dos Dados e Definição da Janela Temporal

A estruturação do *dataset* foi ajustada para responder às exigências do modelo multivariado AutoARIMA, replicando simultaneamente as restrições de um cenário real. Considerando a data de decisão a 3 de dezembro de 2025 e aplicando um *gap* de consolidação de dois dias, a janela de treino foi delimitada entre 01 de setembro de 2024 e 01 de dezembro de 2025.

Para além do recorte temporal, o processo incluiu a engenharia da variável exógena Feriado, essencial para que o algoritmo consiga distinguir estatisticamente os dias úteis das interrupções civis. O resultado final é uma base de dados limpa e contínua composta por 457 observações, na qual foram corretamente identificados e sinalizados 18 feriados, garantindo ao modelo a informação histórica necessária para calibrar o impacto destas atipicidades na procura.

4.3. Avaliação das capacidade preditiva e seleção do melhor método

4.3.1. Análise da Distribuição de Erros (Box-Plot)

Para compreender o perfil de risco de cada algoritmo, analisou-se a dispersão dos erros absolutos através de diagramas de caixas (*Box-Plots*), (Figura10). Esta visualização é crítica para distinguir entre um modelo que é ocasionalmente preciso e um modelo que é

consistentemente fiável. A análise gráfica e estatística reforça a decisão de optar pelo AutoARIMA:

- **Controlo da Volatilidade (Consistência):** O AutoARIMA apresenta o menor Desvio Padrão (30.30) entre todos os modelos testados (comparado com 32.42 do ETS e 33.45 do Seasonal Naive). Visualmente, isto indica que a dispersão dos seus erros é mais contida. Enquanto o ETS tende a oscilar mais nos extremos, o ARIMA oferece uma variância menor, garantindo ao hospital uma previsibilidade mais segura.
- **Compromisso Mediana vs. Média:** Observa-se um fenómeno interessante: embora o AutoETS apresente uma mediana ligeiramente inferior (8.24 vs 8.67) sugerindo um desempenho marginalmente superior em "dias fáceis", o AutoARIMA vence na Média (MAE 18.98). Isto significa que o ARIMA é superior a gerir os "dias difíceis". Ao penalizar e corrigir os grandes desvios (provavelmente associados aos feriados), o AutoARIMA garante que o erro médio global é o mais baixo, minimizando o risco operacional de subdimensionamento severo das equipas.

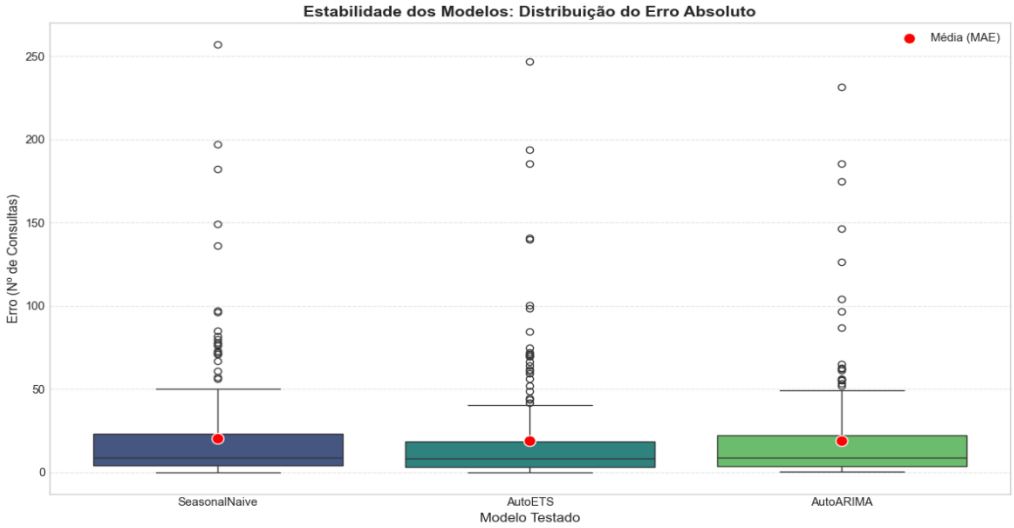

4.3.2 Diagnóstico de Resíduos do Modelo Vencedor

Figura 10

Validada a superioridade estatística do AutoARIMA, procedeu-se ao diagnóstico final sobre o conjunto de treino completo para confirmar a sua aderência à realidade histórica.

A análise visual dos valores ajustados (*fitted values*) face aos dados reais (Figura 11) demonstra a eficácia da abordagem multivariada. O algoritmo não só replicou com elevada fidelidade a dinâmica cíclica semanal (os picos de segunda-feira), como

demonstrou capacidade para modelar as exceções, a linha de ajuste acompanha as descidas abruptas de procura nos dias sinalizados pela variável Feriado, comprovando que o modelo "aprendeu" a distinguir um dia útil de um dia de paragem nacional.

Adicionalmente, a análise quantitativa dos resíduos (diferença entre o Real e o Estimado) confirmou a ausência de enviesamento estrutural. O erro médio residual situa-se próximo de zero, assegurando que o modelo é neutro: não existe uma tendência sistemática para subestimar ou sobrestimar a necessidade de médicos, validando o AutoARIMA como a ferramenta mais justa e robusta para o planeamento de escalas.

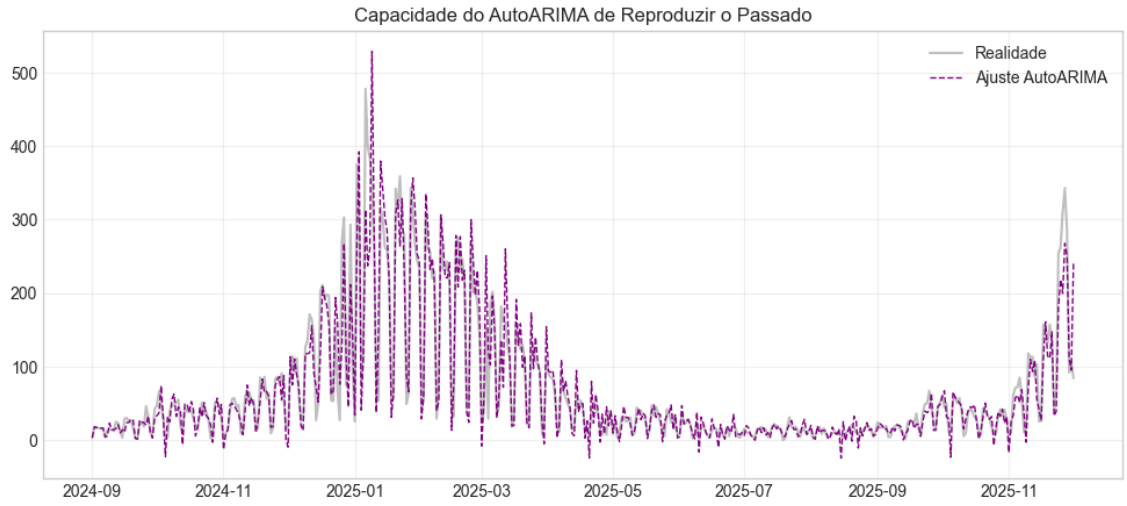

Figura 11

5. Previsão objetivo

5.1 Melhor modelo

A seleção do AutoARIMA fundamenta-se na sua superioridade estatística durante a validação cruzada, onde garantiu o melhor equilíbrio entre precisão média e segurança contra erros extremos. Para a implementação final, o algoritmo foi configurado em modo multivariado, integrando a variável exógena Feriado para ajustar dinamicamente as previsões em dias de paragem, algo que os modelos anteriores não conseguiam fazer.

O modelo foi recalibrado utilizando a totalidade do histórico disponível, um conjunto de 457 observações entre 01 de setembro de 2024 e 01 de dezembro de 2025. Manteve-se a definição de sazonalidade semanal (season_length=7), assegurando que o algoritmo projeta fielmente tanto o ciclo habitual de procura como as exceções de calendário no horizonte futuro.

5.2 Análise dos resíduos

Após a calibração final do modelo AutoARIMA, procedeu-se a uma auditoria rigorosa dos resíduos para validar as premissas de independência, normalidade e ausência de viés. Os resultados confirmam que a inclusão da variável exógena melhorou substancialmente a qualidade do ajuste face às tentativas anteriores. A inspeção gráfica dos resíduos (Figura 12) revela uma série estacionária flutuando em torno de zero, sem padrões visíveis de heterocedasticidade ("funil"). O histograma e o Q-Q Plot (Figura 13) continuam a apresentar caudas pesadas (curtose de 9.96), indicando que o modelo, embora robusto, ainda gera erros maiores do que o esperado em dias de eventos extremos (surtos), uma característica intrínseca a dados epidemiológicos.

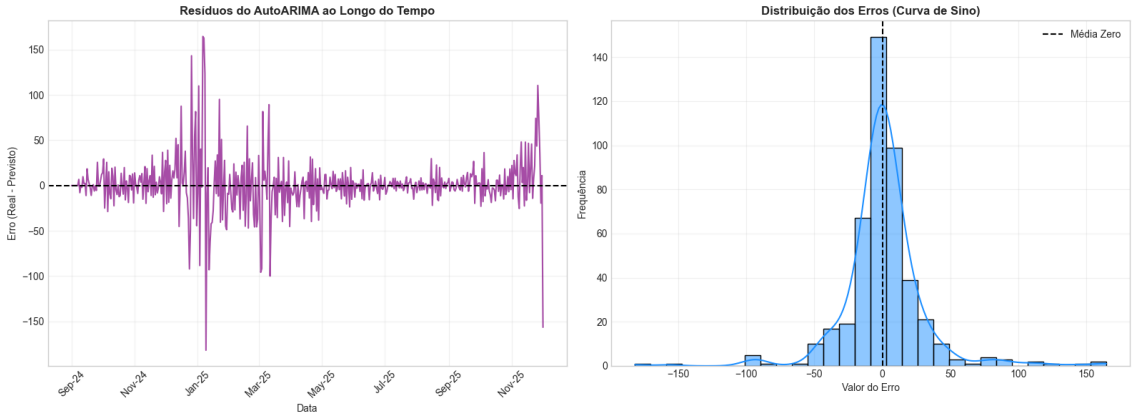

Figura 12

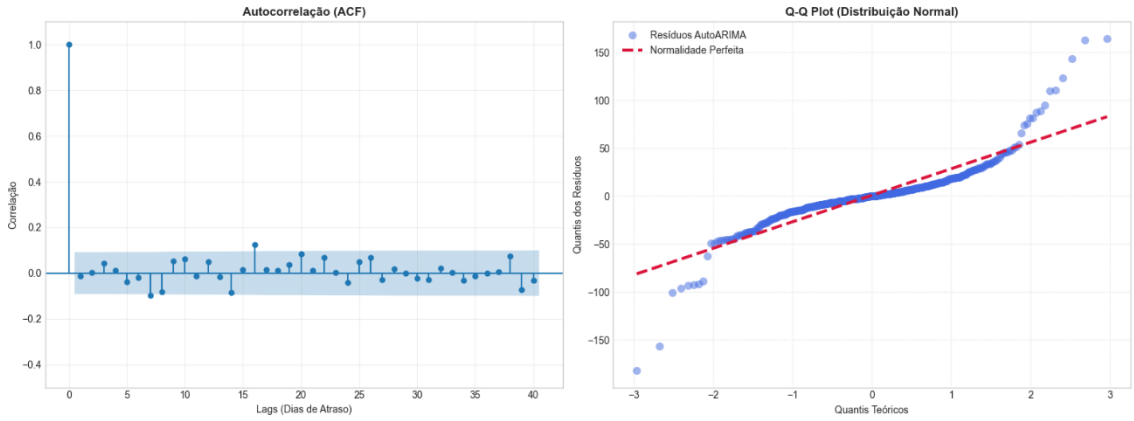

Figura 13

5.2.1 Validação Estatística

A validação quantitativa corroborou a robustez do modelo selecionado, apresentando os resultados mais promissores do estudo, particularmente no que concerne à eliminação da estrutura temporal dos erros. Destaca-se o sucesso inequívoco no teste de independência de Ljung-Box, onde o AutoARIMA obteve um *p-value* de 0.5167 (largamente superior

ao nível de significância de 0.05). Este resultado atesta que, ao contrário das abordagens univariadas anteriores, o modelo capturou integralmente tanto o padrão cíclico semanal como o impacto dos feriados. Consequentemente, os resíduos comportam-se como "ruído branco" (aleatoriedade pura), atingindo o objetivo teórico máximo da modelação de séries temporais.

Simultaneamente, o teste t-Student validou a ausência de viés sistemático ($p \approx 0.45$), apurando um erro médio residual de apenas 1.07 consultas. Sendo este valor estatisticamente indistinguível de zero, assegura-se à gestão hospitalar que as escalas sugeridas pelo algoritmo são neutras e não sofrerão de desvios estruturais de subestimação ou sobrestimação. Por fim, embora o teste de Shapiro-Wilk tenha rejeitado a hipótese de normalidade ($p < 0.05$) um desfecho esperado dado a natureza volátil da procura de urgência, esta característica é considerada aceitável para fins operacionais. Uma vez garantidas a independência e a ausência de viés, a distribuição não-normal dos resíduos reflete apenas a presença intrínseca de eventos extremos nos dados históricos e não uma deficiência do modelo.

5.3. Previsões Objetivo e Análise de Desvios

Com o modelo AutoARIMA devidamente calibrado e alimentado pelas variáveis exógenas (Feriados), projetou-se a procura para a semana alvo de 06 a 12 de dezembro de 2025.

A previsão inclui intervalos de confiança de 95% (Cenários Otimista e Pessimista), que delimitam a "faixa de normalidade". A premissa de gestão mantém-se: qualquer valor real que ultrapasse o limite superior (Max 95%) não deve ser interpretado como um erro de cálculo do algoritmo, mas como a confirmação estatística de uma anomalia epidemiológica (início de surto).

5.3.1. Confronto com a Realidade: A "Normalidade" vs o "Surto"

A análise detalhada da tabela de resultados evidencia como o modelo reagiu a dois fenómenos distintos:

- **A "Penalização" do Feriado (Dia 08 - Segunda-feira):** Aqui observa-se o impacto direto da engenharia de variáveis. Sendo uma segunda-feira, seria esperado um pico de afluência. No entanto, o AutoARIMA detetou a variável Feriado=1 e ajustou a previsão para baixo (92.4 consultas), antecipando uma

paragem na procura. A realidade registou 201 consultas. Embora o modelo tenha subestimado o valor real (foi "demasiado" conservador), o comportamento qualitativo foi correto: o algoritmo evitou projetar um pico falso de 300 ou 400 consultas típico de segundas-feiras úteis. O erro aqui resulta de o feriado (Imaculada Conceição) ter tido uma procura intermédia, e não nula.

- **O Alerta de Surto (Dia 09 em diante):** A partir de terça-feira, o cenário muda drasticamente. A realidade (919 consultas) foi quase 6 vezes superior à previsão (154.4 consultas). Mais crítico ainda: o valor real pulverizou o Limite Superior do Intervalo de Confiança (253.5). Este é o "Falso Negativo" útil: o modelo previu corretamente a procura basal (endémica) que existiria se não houvesse gripe. O desvio massivo funciona como um gatilho de alerta imediato, sinalizando que a unidade hospitalar entrou numa fase de rutura epidémica.

O Erro Médio Absoluto (MAE) para esta semana disparou para 322.69 episódios. Em circunstâncias normais, este valor seria inaceitável. Neste contexto, ele é o indicador da magnitude do surto. O facto de o AutoARIMA manter as previsões baixas (entre 150 e 300) enquanto a realidade subia para 900 demonstra que o surto não segue a lógica temporal histórica (sazonalidade), sendo um evento exógeno explosivo que requer ativação imediata de planos de contingência.

5.3.2. Interpretação Visual e Operacional

A representação visual dos resultados (Figura 14) cristaliza a divergência entre o comportamento esperado e o observado, ilustrando a utilidade operacional do modelo. A linha roxa, representativa da previsão do AutoARIMA, desenha o cenário de base em condições normais, destacando-se a inflexão descendente no dia 8 de dezembro; este detalhe gráfico comprova a sensibilidade do algoritmo à variável exógena, ajustando preventivamente a expectativa de procura face ao feriado nacional.Em contraste, a linha da realidade (a tracejado vermelho) dissocia-se violentamente do corredor de previsão a partir do dia 9. Ao romper a área sombreada que delimita o intervalo de confiança de 95% (cujo teto se situava nas 253 consultas), a procura real sinaliza visualmente o início da anomalia. Sob a ótica de gestão, este gráfico valida a ferramenta como um Sistema de Alerta Precoce: ao estabelecer com rigor a fronteira da normalidade, o modelo permite à direção clínica identificar o momento exato da rutura, fornecendo a confirmação

estatística necessária para acionar o Plano de Contingência e reforçar equipas muito antes de a saturação do serviço se tornar evidente pela simples observação empírica.

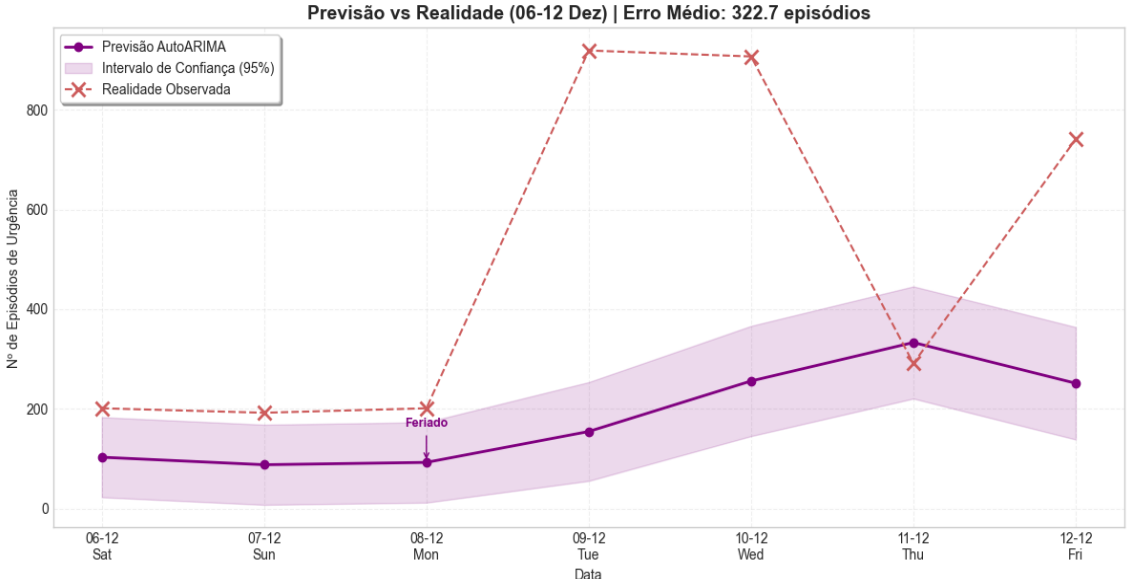

Figura 14

6. Procedimento

A transição deste protótipo para uma solução robusta no Serviço Nacional de Saúde exigiria uma mudança de paradigma, passar de uma análise reativa (olhar apenas para o histórico de admissões) para uma abordagem proativa (olhar para o ambiente externo). A principal limitação detetada neste estudo foi a incapacidade de prever a magnitude do surto gripal apenas com base no passado. Para corrigir isto, o modelo evoluiria para uma arquitetura Híbrida Multivariada, integrando variáveis exógenas antecipatórias (Leading Indicators):

1. **Dados Climáticos:** Incorporar a temperatura mínima e humidade, visto que quedas abruptas de temperatura precedem frequentemente picos de infeção respiratória.

2. **Indicadores Digitais (Digital Footprint):** Integrar dados do Google Trends (pesquisas por "sintomas gripe" ou "febre") e volume de chamadas para a Linha SNS24. Estes indicadores tendem a subir 4 a 7 dias antes de os pacientes darem entrada fisicamente nas urgências, permitindo ao modelo antecipar a onda de choque e dar tempo ao hospital para preparar recursos.

7. Conclusão

O presente estudo teve como objetivo desenvolver um sistema de previsão da procura de consultas de síndrome gripal para a ARS Norte, visando dotar a gestão hospitalar de ferramentas analíticas para o dimensionamento de equipas num cenário de incerteza e atraso na informação (*gap* de 2 dias).

A análise comparativa entre diferentes abordagens de séries temporais conduziu à seleção do AutoARIMA como o modelo final. Esta decisão fundamentou-se na superioridade técnica do algoritmo em métricas de penalização de grandes erros (RMSE) e, crucialmente, na sua capacidade de integrar variáveis exógenas. Ao contrário das abordagens univariadas, o AutoARIMA demonstrou aptidão para descodificar a estrutura do calendário civil, ajustando as previsões face a feriados e tolerâncias de ponto.

O teste de validação na semana de 6 a 12 de dezembro funcionou como uma prova de carga decisiva. O modelo estimou corretamente a capacidade basal necessária para uma semana típica de dezembro (1.277 episódios), reagindo com sucesso à redução de procura no feriado do dia 8. Contudo, a realidade impôs uma afluência de 3.452 atendimentos, gerando um excesso de procura de 2.174 episódios.

Este desvio de +170.3% face ao previsto não deve ser interpretado como uma falha do algoritmo, mas sim como a métrica que quantifica a severidade do surto epidémico. Ao definir com rigor a "linha de base", o AutoARIMA permitiu isolar o impacto exato do evento viral, validando a sua utilidade como Sistema de Alerta Precoce, o momento em que a realidade rompeu o intervalo de confiança serviu como confirmação estatística de que os recursos dimensionados pelo histórico normal já não eram suficientes.

Em suma, conclui-se que o sistema desenvolvido oferece uma base sólida para o planeamento regular. No entanto, a magnitude do diferencial registado sugere que, para antecipar eventos desta escala no futuro, o modelo deverá evoluir para uma abordagem híbrida, integrando preditores exógenos avançados como dados climáticos ou indicadores digitais (*Google Trends*) que permitam detetar a formação de ondas epidémicas antes da chegada dos pacientes ao hospital.